ĐẠI HỌC QUỐC GIA TP HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC

CS221.F31.LT.TTNT
Xử lý ngôn ngữ tự nhiên

So sánh tóm tắt rút trích và tóm lược trên tin tức tiếng Việt

Lead n TextRank ViT5
ROUGE trên 100 và 500 bài kiểm thử

Nhóm 14
Nguyễn Trí Toàn 26410135
Nguyễn Văn Thái 26410108
Đỗ Quốc Hoàng 26410043

Giảng viên hướng dẫn
TS. Đặng Văn Thìn

github.com/hoangdq08/uit-vietnews-summarization

1 Tóm tắt

Báo cáo so sánh ba hệ tóm tắt tin tức tiếng Việt trên 100 bài đầu của tập test Vietnews (test_tokenized): Lead-3, TextRank, và checkpoint VietAI/vit5-base-vietnews-summarization. Nhóm không fine-tune ViT5. Độ đo là ROUGE-1/2/L (F1) sau khi thay dấu gạch dưới bằng khoảng trắng trên cả bản tóm tắt và gold. ViT5 đạt ROUGE cao hơn một chút (R-1 = 0,2664) so với Lead-3 (0,2507) và TextRank (0,2428). Trên 500 bài, ViT5 R-1 = 0,2784 (Lead-1 = 0,2719). Rà soát định tính 100 bài: ViT5 sai hoặc gán nhầm sự kiện so với thân bài ở 24 bài; Lead-3 có thể bỏ trọng tâm của gold dù lấy câu từ thân bài.

2 Đặt vấn đề

Tin điện tử dài. Người đọc và tòa soạn cần bản ngắn. Máy làm theo hai hướng: rút trích (chọn câu có sẵn) và tóm lược (sinh câu mới). Câu hỏi nghiên cứu: trên cùng tập test tiếng Việt, ba hệ khác nhau thế nào về ROUGE, và khi rà soát định tính thì mỗi hệ sai kiểu gì?

Phạm vi là tóm tắt đơn văn bản trên dữ liệu công bố. Nhóm không huấn luyện thêm ViT5 và không thu thập bài báo mới.

3 Bài toán

Input. Thân bài tiếng Việt đã tách từ (dấu “_”).

Output. Bản tóm tắt ngắn: Lead-3 và TextRank lấy 3 câu; ViT5 sinh văn bản.

Gold. Trường abstract trong file Vietnews (tách khỏi thân bằng dòng trống).

Độ đo. ROUGE-1, ROUGE-2, ROUGE-L (F1), trên cùng danh sách ID trong từng mẫu 100 hoặc 500 bài.

4 Dữ liệu

Nguồn: https://github.com/ThanhChinhBK/vietnews, thư mục data/test_tokenized. Mỗi file: tiêu đề, abstract, thân bài. Nhóm lấy 500 file đầu theo tên (000001.txt.seg đến 000500.txt.seg). Mẫu 100 bài đầu là tập con dùng cho phân tích lỗi và độ dài. Không thay đổi split hoặc tách từ lại. Mẫu không ngẫu nhiên nên kết quả chỉ mô tả các bài đã chọn.

5 Phương pháp

5.1 Lead n

Lead-n lấy tối đa n câu đầu thân bài. Thực nghiệm gồm n bằng 1, 3 và 5 trên 500 bài; mẫu 100 bài dùng Lead-3. Phương pháp không cập nhật trọng số.

5.2 TextRank

Biểu diễn câu bằng TF-IDF (sklearn), ma trận cosine, PageRank 40 vòng, hệ số 0,85. Lấy 3 câu điểm cao, sắp lại theo thứ tự xuất hiện trong bài.

5.3 ViT5

Checkpoint VietAI/vit5-base-vietnews-summarization được tác giả fine-tune trên Vietnews. Project giữ nguyên trọng số. Input chỉ gồm thân bài, không có prefix, thêm </s>, tối đa 1.024 token. Sinh greedy với num_beams=1, do_sample=False, max_length=256. Thực nghiệm baseline chạy trên

một GPU Tesla T4 (cuda:0) ở Kaggle, dùng transformers 4.44.2 và T5Tokenizer. Giới hạn token không phải giới hạn số từ tiếng Việt.

5.4 ROUGE

Dùng thư viện rouge-score, báo F1, không stemming hoặc chuyển chữ thường. Prediction và gold đều thay dấu gạch dưới bằng khoảng trắng, rồi tách theo khoảng trắng để thống nhất cách biểu diễn. ROUGE-1 đo trùng token đơn, ROUGE-2 đo trùng cặp token liên tiếp, ROUGE-L dựa trên dãy con chung dài nhất. Điểm không xác minh sự thật của nội dung. Không so trực tiếp với kết quả bài báo do chưa xác nhận cùng tokenizer và thiết lập đánh giá.

6 Kết quả thực nghiệm

Bảng 1. ROUGE F1 trên 100 bài test đầu (cùng id).

Hệ	ROUGE-1	ROUGE-2	ROUGE-L
Lead-3	0,2507	0,1296	0,1841
TextRank	0,2428	0,1100	0,1730
ViT5	0,2664	0,1341	0,2084

ViT5 có điểm trung bình cao hơn Lead-3 và TextRank trên mẫu này. Lead-3 cao hơn TextRank. Vị trí ý chính ở đầu tin là một giả thuyết giải thích, chưa được kiểm chứng bằng thí nghiệm riêng. Chưa kiểm định ý nghĩa thống kê của chênh lệch.

6.1 Theo độ dài bài

Chia 100 bài theo số token cách trắng trong body đã tách từ, trước khi thay dấu gạch dưới. Ngưỡng 300 và 500 làm tròn phân vị trên mẫu này (p33 khoảng 298, p67 khoảng 492). Đây là độ dài theo từ đã tách, khác số token SentencePiece của ViT5. Điểm ROUGE vẫn dùng chuẩn hóa giống bảng chính.

Bảng 1b. ROUGE-1 theo độ dài thân bài.

Nhóm	n	Lead-3	TextRank	ViT5
Ngắn (<300 token)	34	0,2581	0,2672	0,2919
Trung (300–499)	33	0,2638	0,2409	0,2549
Dài (≥500 token)	33	0,2298	0,2194	0,2519

Về ROUGE-1, ViT5 cao nhất ở nhóm ngắn và dài, Lead-3 cao nhất ở nhóm trung bình. Ở nhóm dài, ROUGE-1 của cả ba thấp hơn nhóm trung bình. Kết luận này không áp dụng cho mọi độ đo: ROUGE-2 và ROUGE-L của ViT5 ở nhóm dài cao hơn nhóm trung bình. Đây là mô tả 100 bài, không xác định quan hệ nhân quả.

6.2 Kết quả trên 500 bài

Đánh giá 500 bài 000001 đến 000500, trong đó 100 prediction đầu trùng kết quả mẫu 100 bài. Oracle-3 dùng gold để chọn tổ hợp ba câu tối đa ROUGE-1; code chuyển sang greedy khi số tổ hợp vượt 30.000. Với tối đa 39 câu/bài trong mẫu này, chưa cần nhánh greedy. Oracle là mốc tham chiếu sử dụng đáp án, không phải hệ triển khai thực tế hoặc trần cho mọi độ dài tóm tắt. Lead-1 cao hơn Lead-3 và Lead-5. ViT5 đạt 0,2784, cao hơn Lead-1 0,2719 về ROUGE-1.

Bảng 1c. ROUGE F1, n=500.

Hệ	ROUGE-1	ROUGE-2	ROUGE-L
Lead-1	0,2719	0,1305	0,2092
Lead-3	0,2569	0,1294	0,1856
Lead-5	0,2256	0,1199	0,1624
TextRank-3	0,2499	0,1198	0,1815
ViT5	0,2784	0,1474	0,2233
Oracle-3	0,4646	0,2793	0,3410

6.3 Ảnh hưởng của đầu vào ViT5

Thí nghiệm A/B giữ nguyên checkpoint và cấu hình sinh, chỉ thay dấu gạch dưới trong body bằng khoảng trắng ở nhánh B. Trên cùng 500 bài, B tăng ROUGE và giảm số input vượt 1.024 token. Đây là phân tích khám phá trên test, chưa áp dụng vào pipeline chính.

Bảng 1d. A/B đầu vào ViT5 trên 500 bài

Đầu vào	ROUGE-1	ROUGE-2	ROUGE-L	Bài bị cắt
Giữ dấu _	0,2784	0,1474	0,2233	120/500
Khoảng trắng	0,3124	0,1796	0,2560	38/500

ROUGE tăng không chứng minh factuality tốt hơn. Rà soát sơ bộ bằng AI trên 20 bài trong mẫu xác nhận 100 bài vẫn phát hiện nhánh B trộn sự kiện hoặc đảo vai người. Chưa có hai người chấm độc lập trên toàn mẫu. Mẫu 500 chứa các mẫu nhỏ trước đó, không phải tập kiểm chứng độc lập. Chi tiết thiết kế và kết quả: docs/VIT5_INPUT_AB.md và docs/VIT5_CONFIRM100.md.

7 Phân tích lỗi (100 bài rà soát định tính)

Đối chiếu gold, thân bài và ba hệ trên đủ 100 bài 000001–000100. ViT5 sai hoặc gán nhầm sự kiện so với thân bài ở 24 bài. Một lượt đọc, không phải hai người chấm. Chi tiết: results/error_analysis.md. Đối chiếu số ghi nhận 7 bài sai hoặc gán nhầm số và 13 bài sót số then chốt của gold. Các nhóm có thể giao nhau; 64 bài do regex phát hiện lệch số là ứng viên kiểm tra, không phải tỷ lệ lỗi đã xác nhận.

Bảng 2. Ba ví dụ ViT5 sai sự thật dù ROUGE có thể không thấp.

Id	Gold	ViT5	Lỗi
000001	Hồ Xuân Huy, 12 năm tù (Đà Nẵng).	Bùi Quang Huy / Vũ nhôm, 3,2 tỷ.	Sai tên
000011	Trộm máy ủi, bán, mua dây chuyền.	“Xe bồn”, thuê sửa chữa.	Bịa đối tượng
000036	Vĩnh chối Rolex 7.000 USD.	Vĩnh “khai cho ông Vĩnh” 27 tỷ.	Gán nhầm lời Dương

Ngoài ra: 000003 ViT5 đảo polarity (“dung dịch chất lượng tốt” trong bài điều tra quảng cáo); 000015 ViT5 đảo người đâm; 000051 Lead-3 gần như không nêu vụ nổ micro; 000066 (bản tin 24h, nhiều tin/bài) cả ba hệ đều cắt, lặp hoặc trộn tin. Lead-3 ít bịa vì lấy câu sẵn có, nhưng hay

lệch gold khi gold là kết luận phiên toà hoặc sapo. TextRank đôi khi lấy câu chú thích ảnh hoặc nhảy chuyên án.

ROUGE cao hơn không chứng minh bản tóm tắt đúng tên, số hoặc quan hệ giữa các sự kiện. Cần đối chiếu output với thân bài. Gold chỉ là tham chiếu cho điểm số và có thể chứa thông tin không xuất hiện trong body.

8 Demo

Ứng dụng Gradio ba cột (Lead-3 | TextRank | ViT5) trên 500 bài đầu, kèm ROUGE từng bài. ViT5 lấy từ results/preds_500.json, không gọi GPU lúc demo. Chạy demo: docker run --rm -p 7860:7860 vietnews-demo. Địa chỉ: http://127.0.0.1:7860.

9 Kết luận và hạn chế

Trên 100 bài, ViT5 ROUGE cao hơn Lead-3 và TextRank một chút; trên 500 bài hơn Lead-1 một chút (0,2784 vs 0,2719). Rà soát định tính 100 bài: ViT5 vẫn sai hoặc gán nhầm ở 24 bài. Rút trích giữ câu trong body nhưng vẫn có thể thiếu ngữ cảnh hoặc lệch trọng tâm sapo.

Hạn chế: mẫu là 500 bài đầu theo tên file, không ngẫu nhiên. Rà soát lỗi một lượt trên 100 bài, chưa có hai người chấm độc lập hoặc kiểm định thống kê. Checkpoint đã được tác giả fine-tune trên Vietnews nên kết quả chưa đo khả năng khái quát sang miền khác; điều này không tự chứng minh model đã thấy các bài test. Chưa đo độ trễ end-to-end của demo hoặc so sánh tốc độ các hệ.

10 Tài liệu

1. Vietnews / VNDS: https://github.com/ThanhChinhBK/vietnews

2. Phan, L., Tran, H., Nguyen, H. và Trinh, T. H. (2022). ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation. NAACL Student Research Workshop, trang 136–142. https://aclanthology.org/2022.naacl-srw.18/

3. Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. Text Summarization Branches Out, trang 74–81. https://aclanthology.org/W04-1013/

4. Mihalcea, R. và Tarau, P. (2004). TextRank: Bringing Order into Text. EMNLP, trang 404–411. https://aclanthology.org/W04-3252/

5. Repo nhóm: https://github.com/hoangdq08/uit-vietnews-summarization

Phụ lục: results/scores.csv, scores_500.csv, preds.json, preds_500.json, error_analysis.md. Slide: slides/CS221-Vietnews-bao-ve.pptx.